

Anticipez les besoins en consommation électrique de bâtiments

Parcours Data Scientist financé par Pôle Emploi

Étudiante: Veronika BEREZHNAIA

Mentor: Gaëtan GOLLIOT

Évaluateur: Denis Lecoeuche

Problématique

- Mon équipe s'intéresse aux émissions des bâtiments **non destinés à l'habitation** à Seattle.
- L'objectif de projet est de **prédire les émissions de gaz à effet de serre et la consommation d'énergie** de ces bâtiments
 - La prédiction doit se baser sur les données déclaratives du permis d'exploitation commerciale: la taille et l'usage des bâtiments, la date de construction, mention de travaux récents, etc.
- L'autre objectif est d'**évaluer l'intérêt de l'"ENERGY STAR Score"**, qui est cher et fastidieux à mesurer, pour la prédiction d'émissions CO₂.

Ma mission

- Tester plusieurs algorithmes de la régression, optimiser les **hyperparamètres** à l'aide d'une validation croisée et choisir l'**algorithme de Machine Learning** avec la meilleure performance prédictive.
- Avant de passer à la modélisation, faire feature engineering (c'est-à-dire créer des nouvelles variables à la base de variables initiales) pour améliorer la performance du modèle.

Sommaire

- L'étape de nettoyage et d'exploration:
 - Analyse exploratoire / première connaissance au jeu de données
 - Nettoyage de données
 - Feature engineering
 - Analyse exploratoire sur des données nettoyées
- L'étape de modélisation, avec la cible non-transformée et avec la cible transformée au logarithme
 - Les principes de fonctionnement des algorithmes
 - La signification de paramètres testés dans la validation croisée
- L'étape de synthèse, comparaison de performance pour la consommation de l'énergie:
 - Comparer les résultats avec la cible non-transformée et transformée au logarithme
 - Comparer les résultats sur le jeu d'entraînement et le jeu de test, pour détecter le sur-apprentissage
 - Comparer les résultats avec EnergyStarScore et sans, pour en évaluer l'intérêt
- L'étape de synthèse, comparaison de performance pour les émissions CO₂
- Conclusion, quel modèle est le meilleur

Matrice de corrélation : cibles et EnergyStarScore

ENERGYSTARScore	TotalGHGEmissions	SiteEnergyUse(kBtu)
OSEBuildingID	-0.1	-0.12
ZipCode	-0.048	-0.042
CouncilDistrictCode	0.017	0.04
Latitude	-0.026	-0.021
Longitude	0.037	0.034
YearBuilt	0.013	0.027
NumberofBuildings	0.41	0.69
NumberofFloors	0.14	0.21
PropertyGFATotal	0.53	0.8
PropertyGFAParking	0.089	0.17
PropertyGFABuilding(s)	0.55	0.81
LargestPropertyUseTypeGFA	0.58	0.84
SecondLargestPropertyUseTypeGFA	0.51	0.63
ThirdLargestPropertyUseTypeGFA	0.68	0.75
ENERGYSTARScore	-0.1	-0.09
SiteEUI(kBtu/sf)	0.29	0.3
SiteEUIWN(kBtu/sf)	0.27	0.27
SourceEUI(kBtu/sf)	0.23	0.3
SourceEUIWN(kBtu/sf)	0.22	0.27
SiteEnergyUse(kBtu)	0.86	1
SiteEnergyUseWN(kBtu)	0.86	0.72
SteamUse(kBtu)	0.68	0.6
Electricity(kWh)	0.69	0.96
Electricity(kBtu)	0.69	0.96
NaturalGas(therms)	0.73	0.51
NaturalGas(kBtu)	0.73	0.51
DefaultData	-0.017	-0.023
TotalGHGEmissions	1	0.86
GHGEmissionsIntensity	0.47	0.31

Mise en forme des tableaux



- Avant de concaténer :
 - Sélectionner les variables qui s'agissent de données déclaratives du permis d'exploitation commerciale
 - Jeter des variables incongrues en 2015 et 2016, tels que Code Zip
 - Assurer que les noms de colonnes sont les mêmes pour les deux tableaux
 - Vérifier que les distributions de colonnes numériques se ressemblent pour années 2015 et 2016
 - Transformer l'année de construction en l'âge de bâtiment
 - Extraire des colonnes 'Latitude' et 'Longitude' de la colonne 'Localisation'

Nettoyage de données


- Remplir des valeurs manquants (nombre de bâtiments, nombre d'étages)
- Mise en forme du texte (registre, effacer des symboles du service)
- Sélectionner des bâtiments non destinés à l'habitation
- Éliminer des individus sans valeurs cibles
- Gérer les incohérences :
 - Valeurs négatives
 - Site Energy Use > Source Energy Use,
 - Surface Totale inégale à la somme de surfaces de composants
- Effacer des duplicatas (numéro d'identité de bâtiment et la surface totale)

Traitement des valeurs aberrantes

- Colonne 'Outlier' dans les jeux de données s'agit de outliers par rapport au ENERGYSTARSCORE






CO2 emissions




La méthode est d'enelever des valeurs plus éloignées que 1.5 fois Interval InterQuantile. J'ai choisi des targets pour estimer les intervalles, et j'ai pris leur logarithme, car lui, il a une distribution normale.

1 % de données supprimées
(39 sur 3183)

Zoomed CO2 emissions (< 1000)



Corrélation entre deux variables catégorielles



Corrélation entre deux variables catégorielles

