



Émissions : l'utilité du passage de la cible au logarithme, avec et sans Energy Star Score


Avec Energy Star Score




Avec Energy Star Score




Avec Energy Star Score




Random state = 1



Random state = 2



Random state = 3




Sans Energy Star Score

Sans Energy Star Score


Sans Energy Star Score

Émissions CO₂ : sur-apprentissage des modèles


Avec Energy Star Score




Avec Energy Star Score




Avec Energy Star Score




Random state = 7



Random state = 4



Random state = 3




Sans Energy Star Score

Sans Energy Star Score


Sans Energy Star Score

Émissions CO₂ : l'utilité de l'Energy Star Score


Test set




Test set




Test set




Random state = 1



Random state = 2



Random state = 3



With log transform

With log transform

With log transform

Conclusion

- La méthode qui mets de côté le jeu de test, fait l'optimisation de hyperparamètres avec la validation croisée sur le jeu d'entraînement, puis fait la prédiction sur le jeu de test et le rangement par l'erreur quadratique moyenne, ressort le nom de modèle le plus performant.
- Ce nom de modèle n'est pas toujours le même : il change en fonction de random state, la sélection initiale du jeu de test.
- Néanmoins, cette méthode permet de choisir le meilleur modèle après l'exécution du notebook de plusieurs fois : c'est **XGB Regressor**, et voilà pourquoi :
 - Il figure un peu plus souvent le gagnant, celui qui prend la première place ;
 - Quand il n'est pas le gagnant, la différence entre le gagnant et XGB Regressor est petite, ce qui n'est pas le cas pour autres modèles : sa performance est donc plus stable, plus robuste au choix de jeu de test (random state)
- **J'ai choisi de ne pas transformer la cible au son logarithme** : ce modèle performe mieux avec la cible non-transformée. Sans oublier que autres modèles sont mieux avec le passage au log, comme Random Forest, ou largement mieux, comme SVR.
- **Pour les émissions CO₂ le meilleur algorithme est XGB Regressor sans log transform de la cible.**
- La performance de la prédiction de la consommation d'énergie est meilleure avec **ENERGYSTARSCORE**. Elle est mieux de 5 à 33 % (si on prend l'erreur sans ENERGYSTARSCORE à 100%). Il est donc justifiable d'utiliser l'ENERGYSTARSCORE pour les modèles, mais pour en prendre de nouvelles mesures, il faut aussi estimer si le coût et la difficulté de le mesurer vaut ce gain en précision de la prédiction.
- La performance de la prédiction d'émissions de gaz à effet n'est pas meilleure avec **ENERGYSTARSCORE** : dans plusieurs expériences avec la sélection du jeu de test (random state) différents, parfois le résultat est meilleur avec lui, parfois sans. Et la différence entre ces valeurs d'erreurs est 5-10 %. Pour prédictions d'émission, ce score n'est pas utile.